

Rete neurale 3→3→2→1: forward, MSE e backprop (SGD su 3 esempi)

1. Dati, normalizzazione e obiettivo

Input: altezza (cm), peso (kg), età (anni). Output: rischio obesità $y \in \{0, 1\}$ (0=no, 1=sì).

$$x_1 = \frac{\text{altezza}}{200}, \quad x_2 = \frac{\text{peso}}{150}, \quad x_3 = \frac{\text{età}}{100}$$

Tabella training (10 esempi). In questo documento useremo per SGD “vero” i primi 3 esempi (#1,#2,#3) in sequenza.

#	Altezza	Peso	Età	y	x_1	x_2	x_3
1	170	65	25	0	0.850	0.4333	0.25
2	160	80	45	1	0.800	0.5333	0.45
3	180	90	35	1	0.900	0.6000	0.35
4	175	70	30	0	0.875	0.4667	0.30
5	155	95	50	1	0.775	0.6333	0.50
6	165	55	22	0	0.825	0.3667	0.22
7	172	110	40	1	0.860	0.7333	0.40
8	168	60	28	0	0.840	0.4000	0.28
9	158	75	33	1	0.790	0.5000	0.33
10	185	78	27	0	0.925	0.5200	0.27

2. Architettura e funzioni

Architettura: 3 input → 3 neuroni → 2 neuroni → 1 neurone.

Attivazione (tutti i neuroni): sigmoide $\sigma(z) = \frac{1}{1+e^{-z}}$, con derivata $\sigma'(z) = \sigma(z)(1 - \sigma(z))$.

Loss (MSE su 1 esempio):

$$L = (\hat{y} - y)^2$$

Learning rate: $\eta = 0.5$.

2.1 Schema

$x_1, x_2, x_3 \rightarrow [a_1, a_2, a_3] \rightarrow [g_1, g_2] \rightarrow \hat{y}$

con bias in ogni neurone.

3. Forward (formule, senza matrici)

Strato 1:

$$z_1 = w_{11}x_1 + w_{12}x_2 + w_{13}x_3 + b_1, \quad a_1 = \sigma(z_1)$$

$$z_2 = w_{21}x_1 + w_{22}x_2 + w_{23}x_3 + b_2, \quad a_2 = \sigma(z_2)$$

$$z_3 = w_{31}x_1 + w_{32}x_2 + w_{33}x_3 + b_3, \quad a_3 = \sigma(z_3)$$

Strato 2:

$$s_1 = v_{11}a_1 + v_{12}a_2 + v_{13}a_3 + c_1, \quad g_1 = \sigma(s_1)$$

$$s_2 = v_{21}a_1 + v_{22}a_2 + v_{23}a_3 + c_2, \quad g_2 = \sigma(s_2)$$

Output:

$$t = u_1g_1 + u_2g_2 + d, \quad \hat{y} = \sigma(t)$$

4. Backprop: dimostrazione della regola $\frac{dL}{dw_{11}} = \delta_{a1}x_1$ e $\frac{dL}{db_1} = \delta_{a1}$

Per il neurone a_1 (strato 1): $z_1 = w_{11}x_1 + w_{12}x_2 + w_{13}x_3 + b_1$, $a_1 = \sigma(z_1)$.

$$\frac{dL}{dw_{11}} = \frac{dL}{dz_1} \cdot \frac{dz_1}{dw_{11}}$$

Definisco $\delta_{a1} \equiv \frac{dL}{dz_1}$. Poiché z_1 dipende linearmente da w_{11} : $\frac{dz_1}{dw_{11}} = x_1$. Quindi:

$$\boxed{\frac{dL}{dw_{11}} = \delta_{a1} x_1}$$

Analogamente $\frac{dz_1}{dw_{12}} = x_2$ e $\frac{dz_1}{dw_{13}} = x_3$, quindi $\frac{dL}{dw_{12}} = \delta_{a1}x_2$, $\frac{dL}{dw_{13}} = \delta_{a1}x_3$.

Per il bias: $\frac{dz_1}{db_1} = 1$, quindi:

$$\boxed{\frac{dL}{db_1} = \delta_{a1}}$$

5. Backprop (deltas e gradienti, formule generali)

Output:

$$\frac{dL}{d\hat{y}} = \frac{dL}{d\hat{y}-y} \cdot \frac{d(\hat{y}-y)}{d\hat{y}} = 2(\hat{y}-y)\hat{y}(1-\hat{y})$$

$$\frac{dL}{du_1} = \delta_{out}g_1, \quad \frac{dL}{du_2} = \delta_{out}g_2, \quad \frac{dL}{dd} = \delta_{out}$$

Strato 2:

$$\delta_{g1} = \frac{dL}{ds_1} = \delta_{out}u_1g_1(1 - g_1), \quad \delta_{g2} = \frac{dL}{ds_2} = \delta_{out}u_2g_2(1 - g_2)$$

$$\frac{dL}{dv_{1j}} = \delta_{g1}a_j, \quad \frac{dL}{dc_1} = \delta_{g1} \quad \frac{dL}{dv_{2j}} = \delta_{g2}a_j, \quad \frac{dL}{dc_2} = \delta_{g2}$$

Strato 1:

$$\delta_{a1} = \frac{dL}{dz_1} = (\delta_{g1}v_{11} + \delta_{g2}v_{21})a_1(1 - a_1)$$

$$\delta_{a2} = \frac{dL}{dz_2} = (\delta_{g1}v_{12} + \delta_{g2}v_{22})a_2(1 - a_2)$$

$$\delta_{a3} = \frac{dL}{dz_3} = (\delta_{g1}v_{13} + \delta_{g2}v_{23})a_3(1 - a_3)$$

$$\frac{dL}{dw_{i1}} = \delta_{ai}x_1, \quad \frac{dL}{dw_{i2}} = \delta_{ai}x_2, \quad \frac{dL}{dw_{i3}} = \delta_{ai}x_3, \quad \frac{dL}{db_i} = \delta_{ai}$$

Update SGD: $\theta \leftarrow \theta - \eta \frac{dL}{d\theta}$ con $\eta = 0.5$.

6. Esecuzione numerica completa: 3 iterazioni SGD sui primi 3 esempi

6.1 Parametri iniziali (prima di iterazione 1)

Strato 1 (w, b):

$$w_{11} = 0.100000, \quad w_{12} = -0.200000, \quad w_{13} = 0.100000, \quad b_1 = 0$$

$$w_{21} = -0.100000, \quad w_{22} = 0.100000, \quad w_{23} = 0.200000, \quad b_2 = 0$$

$$w_{31} = 0.050000, \quad w_{32} = 0.100000, \quad w_{33} = -0.100000, \quad b_3 = 0$$

Strato 2 (v, c):

$$v_{11} = 0.100000, \quad v_{12} = -0.100000, \quad v_{13} = 0.050000, \quad c_1 = 0$$

$$v_{21} = -0.050000, \quad v_{22} = 0.100000, \quad v_{23} = 0.100000, \quad c_2 = 0$$

Output (u, d):

$$u_1 = 0.100000, \quad u_2 = -0.100000, \quad d = 0$$

Iterazione 1: SGD su esempio #1

Input: $x_1 = 0.850000, \quad x_2 = 0.433300, \quad x_3 = 0.250000, \quad y = 0$

Parametri all'inizio dell'iterazione

Strato 1 (w, b):

$$w_{11} = 0.100000, w_{12} = -0.200000, w_{13} = 0.100000, b_1 = 0$$

$$w_{21} = -0.100000, w_{22} = 0.100000, w_{23} = 0.200000, b_2 = 0$$

$$w_{31} = 0.050000, w_{32} = 0.100000, w_{33} = -0.100000, b_3 = 0$$

Strato 2 (v, c):

$$v_{11} = 0.100000, v_{12} = -0.100000, v_{13} = 0.050000, c_1 = 0$$

$$v_{21} = -0.050000, v_{22} = 0.100000, v_{23} = 0.100000, c_2 = 0$$

Output (u, d):

$$u_1 = 0.100000, u_2 = -0.100000, d = 0$$

Forward (tutti i valori intermedi)

Strato 1:

$$z_1 = w_{11}x_1 + w_{12}x_2 + w_{13}x_3 + b_1 = (0.100000)(0.850000) + (-0.200000)(0.433300) + (0.100000)(0.250000) + (0)$$

$$a_1 = \sigma(z_1) = \sigma(0.023340) = 0.505835$$

$$z_2 = w_{21}x_1 + w_{22}x_2 + w_{23}x_3 + b_2 = (-0.100000)(0.850000) + (0.100000)(0.433300) + (0.200000)(0.250000) + (0)$$

$$a_2 = \sigma(z_2) = \sigma(0.008330) = 0.502082$$

$$z_3 = w_{31}x_1 + w_{32}x_2 + w_{33}x_3 + b_3 = (0.050000)(0.850000) + (0.100000)(0.433300) + (-0.100000)(0.250000) + (0)$$

$$a_3 = \sigma(z_3) = \sigma(0.060830) = 0.515203$$

Strato 2:

$$s_1 = v_{11}a_1 + v_{12}a_2 + v_{13}a_3 + c_1 = (0.100000)(0.505835) + (-0.100000)(0.502082) + (0.050000)(0.515203) + (0) =$$

$$g_1 = \sigma(s_1) = \sigma(0.026135) = 0.506533$$

$$s_2 = v_{21}a_1 + v_{22}a_2 + v_{23}a_3 + c_2 = (-0.050000)(0.505835) + (0.100000)(0.502082) + (0.100000)(0.515203) + (0) =$$

$$g_2 = \sigma(s_2) = \sigma(0.076437) = 0.519100$$

Output:

$$t = u_1g_1 + u_2g_2 + d = (0.100000)(0.506533) + (-0.100000)(0.519100) + (0) = -0.001257$$

$$\hat{y} = \sigma(t) = \sigma(-0.001257) = 0.499686$$

Loss (MSE su 1 esempio)

$$L = (\hat{y} - y)^2 = (0.499686 - 0)^2 = 0.249686$$

Backprop: deltas (error signals)

$$\frac{dL}{d\hat{y}} = 2(\hat{y} - y) = 2(0.499686 - 0) = 0.999372$$

$$\frac{d\hat{y}}{dt} = \hat{y}(1 - \hat{y}) = (0.499686)(1 - 0.499686) = 0.250000$$

$$\delta_{out} = \frac{dL}{dt} = \frac{dL}{d\hat{y}} \frac{d\hat{y}}{dt} = 0.999372 \cdot 0.250000 = 0.249843$$

$$\delta_{g1} = \frac{dL}{ds_1} = \delta_{out} u_1 g_1 (1 - g_1) = 0.249843 \cdot 0.100000 \cdot (0.506533)(1 - 0.506533) = 0.006245$$

$$\delta_{g2} = \frac{dL}{ds_2} = \delta_{out} u_2 g_2 (1 - g_2) = 0.249843 \cdot -0.100000 \cdot (0.519100)(1 - 0.519100) = -0.006237$$

$$\delta_{a1} = \frac{dL}{dz_1} = (\delta_{g1} v_{11} + \delta_{g2} v_{21}) a_1 (1 - a_1) = (0.006245 \cdot 0.100000 + -0.006237 \cdot -0.050000) \cdot (0.505835)(1 - 0.505835)$$

$$\delta_{a2} = \frac{dL}{dz_2} = (\delta_{g1} v_{12} + \delta_{g2} v_{22}) a_2 (1 - a_2) = (0.006245 \cdot -0.100000 + -0.006237 \cdot 0.100000) \cdot (0.502082)(1 - 0.502082)$$

$$\delta_{a3} = \frac{dL}{dz_3} = (\delta_{g1} v_{13} + \delta_{g2} v_{23}) a_3 (1 - a_3) = (0.006245 \cdot 0.050000 + -0.006237 \cdot 0.100000) \cdot (0.515203)(1 - 0.515203)$$

Tutti i gradienti (23 valori)

$$\frac{dL}{du_1} = \delta_{out}g_1 = 0.249843 \cdot 0.506533 = 0.126554$$

$$\frac{dL}{du_2} = \delta_{out}g_2 = 0.249843 \cdot 0.519100 = 0.129693$$

$$\frac{dL}{dd} = \delta_{out} = 0.249843$$

$$\frac{dL}{dv_{11}} = \delta_{g1}a_1 = 0.006245 \cdot 0.505835 = 0.003159$$

$$\frac{dL}{dv_{12}} = \delta_{g1}a_2 = 0.006245 \cdot 0.502082 = 0.003136$$

$$\frac{dL}{dv_{13}} = \delta_{g1}a_3 = 0.006245 \cdot 0.515203 = 0.003217$$

$$\frac{dL}{dc_1} = \delta_{g1} = 0.006245$$

$$\frac{dL}{dv_{21}} = \delta_{g2}a_1 = -0.006237 \cdot 0.505835 = -0.003155$$

$$\frac{dL}{dv_{22}} = \delta_{g2}a_2 = -0.006237 \cdot 0.502082 = -0.003131$$

$$\frac{dL}{dv_{23}} = \delta_{g2}a_3 = -0.006237 \cdot 0.515203 = -0.003213$$

$$\frac{dL}{dc_2} = \delta_{g2} = -0.006237$$

$$\frac{dL}{dw_{11}} = \delta_{a1}x_1 = 0.000234 \cdot 0.850000 = 0.000199$$

$$\frac{dL}{dw_{12}} = \delta_{a1}x_2 = 0.000234 \cdot 0.433300 = 0.000101$$

$$\frac{dL}{dw_{13}} = \delta_{a1}x_3 = 0.000234 \cdot 0.250000 = 5.851379e - 05$$

$$\frac{dL}{db_1} = \delta_{a1} = 0.000234$$

$$\frac{dL}{dw_{21}} = \delta_{a2}x_1 = -0.000312 \cdot 0.850000 = -0.000265$$

$$\frac{dL}{dw_{22}} = \delta_{a2}x_2 = -0.000312 \cdot 0.433300 = -0.000135$$

$$\frac{dL}{dw_{23}} = \delta_{a2}x_3 = -0.000312 \cdot 0.250000 = -7.801090e - 05$$

$$\frac{dL}{db_2} = \delta_{a2} = -0.000312$$

$$\frac{dL}{dw_{31}} = \delta_{a3}x_1 = -7.778937e - 05 \cdot 0.850000 = -6.612096e - 05$$

$$\frac{dL}{dw_{32}} = \delta_{a3}x_2 = -7.778937e - 05 \cdot 0.433300 = -3.370613e - 05$$

$$\frac{dL}{dw_{33}} = \delta_{a3}x_3 = -7.778937e - 05 \cdot 0.250000 = -1.944734e - 05$$

$$\frac{dL}{db_3} = \delta_{a3} = -7.778937e - 05$$

Update (SGD)

$$\theta \leftarrow \theta - \eta \frac{dL}{d\theta} \quad (\eta = 0.5)$$

Parametri dopo l'update (fine iterazione):

Strato 1 (w, b):

$$\begin{aligned} w_{11} &= 0.099901, w_{12} = -0.200051, w_{13} = 0.099971, b_1 = -0.000117 \\ w_{21} &= -0.099867, w_{22} = 0.100068, w_{23} = 0.200039, b_2 = 0.000156 \\ w_{31} &= 0.050033, w_{32} = 0.100017, w_{33} = -0.099990, b_3 = 3.889468e - 05 \end{aligned}$$

Strato 2 (v, c):

$$\begin{aligned} v_{11} &= 0.098421, v_{12} = -0.101568, v_{13} = 0.048391, c_1 = -0.003123 \\ v_{21} &= -0.048423, v_{22} = 0.101566, v_{23} = 0.101607, c_2 = 0.003118 \end{aligned}$$

Output (u, d):

$$u_1 = 0.036723, u_2 = -0.164847, d = -0.124921$$

Calcolo esplicito degli aggiornamenti (Iterazione 1)

Regola teorica di update (SGD su 1 esempio). Per ogni parametro scalare θ :

$$\theta^{(1)} = \theta^{(0)} - \eta \left. \frac{\partial L}{\partial \theta} \right|_{\theta^{(0)}, \text{esempio \#1}}$$

dove:

$$\theta^{(0)} = \text{valore prima dell'update}, \quad \eta = 0.5 = \text{learning rate},$$

$$\left. \frac{\partial L}{\partial \theta} \right|_{\theta^{(0)}, \#1} = \text{gradiente calcolato nella backprop dell'iterazione 1}.$$

Strato 1. Esempio esplicito su w_{11} :

$$w_{11}^{(1)} = w_{11}^{(0)} - \eta \left. \frac{\partial L}{\partial w_{11}} \right|_{\theta^{(0)}, \#1} = 0.100000 - 0.5 \cdot 0.000199 = 0.0999005 \approx 0.099901$$

$$w_{12}^{(1)} = w_{12}^{(0)} - \eta \left. \frac{\partial L}{\partial w_{12}} \right|_{\theta^{(0)}, \#1} = -0.200000 - 0.5 \cdot 0.000101 = -0.2000505 \approx -0.200051$$

$$w_{13}^{(1)} = w_{13}^{(0)} - \eta \left. \frac{\partial L}{\partial w_{13}} \right|_{\theta^{(0)}, \#1} = 0.100000 - 0.5 \cdot 5.851379 \times 10^{-5} = 0.0999707 \approx 0.099971$$

$$b_1^{(1)} = b_1^{(0)} - \eta \left. \frac{\partial L}{\partial b_1} \right|_{\theta^{(0)}, \#1} = 0 - 0.5 \cdot 0.000234 = -0.000117$$

$$w_{21}^{(1)} = w_{21}^{(0)} - \eta \left. \frac{\partial L}{\partial w_{21}} \right|_{\theta^{(0)}, \#1} = -0.100000 - 0.5 \cdot (-0.000265) = -0.0998675 \approx -0.099867$$

$$w_{22}^{(1)} = w_{22}^{(0)} - \eta \left. \frac{\partial L}{\partial w_{22}} \right|_{\theta^{(0)}, \#1} = 0.100000 - 0.5 \cdot (-0.000135) = 0.1000675 \approx 0.100068$$

$$w_{23}^{(1)} = w_{23}^{(0)} - \eta \left. \frac{\partial L}{\partial w_{23}} \right|_{\theta^{(0)}, \#1} = 0.200000 - 0.5 \cdot (-7.801090 \times 10^{-5}) = 0.2000390 \approx 0.200039$$

$$b_2^{(1)} = b_2^{(0)} - \eta \frac{\partial L}{\partial b_2} \Big|_{\theta^{(0)}, \#1} = 0 - 0.5 \cdot (-0.000312) = 0.000156$$

$$w_{31}^{(1)} = w_{31}^{(0)} - \eta \frac{\partial L}{\partial w_{31}} \Big|_{\theta^{(0)}, \#1} = 0.050000 - 0.5 \cdot (-6.612096 \times 10^{-5}) = 0.0500331 \approx 0.050033$$

$$w_{32}^{(1)} = w_{32}^{(0)} - \eta \frac{\partial L}{\partial w_{32}} \Big|_{\theta^{(0)}, \#1} = 0.100000 - 0.5 \cdot (-3.370613 \times 10^{-5}) = 0.1000169 \approx 0.100017$$

$$w_{33}^{(1)} = w_{33}^{(0)} - \eta \frac{\partial L}{\partial w_{33}} \Big|_{\theta^{(0)}, \#1} = -0.100000 - 0.5 \cdot (-1.944734 \times 10^{-5}) = -0.0999903 \approx -0.099990$$

$$b_3^{(1)} = b_3^{(0)} - \eta \frac{\partial L}{\partial b_3} \Big|_{\theta^{(0)}, \#1} = 0 - 0.5 \cdot (-7.778937 \times 10^{-5}) = 3.889468 \times 10^{-5}$$

Strato 2.

$$v_{11}^{(1)} = v_{11}^{(0)} - \eta \frac{\partial L}{\partial v_{11}} \Big|_{\theta^{(0)}, \#1} = 0.100000 - 0.5 \cdot 0.003159 = 0.0984205 \approx 0.098421$$

$$v_{12}^{(1)} = v_{12}^{(0)} - \eta \frac{\partial L}{\partial v_{12}} \Big|_{\theta^{(0)}, \#1} = -0.100000 - 0.5 \cdot 0.003136 = -0.101568$$

$$v_{13}^{(1)} = v_{13}^{(0)} - \eta \frac{\partial L}{\partial v_{13}} \Big|_{\theta^{(0)}, \#1} = 0.050000 - 0.5 \cdot 0.003217 = 0.0483915 \approx 0.048391$$

$$c_1^{(1)} = c_1^{(0)} - \eta \frac{\partial L}{\partial c_1} \Big|_{\theta^{(0)}, \#1} = 0 - 0.5 \cdot 0.006245 = -0.003123$$

$$v_{21}^{(1)} = v_{21}^{(0)} - \eta \frac{\partial L}{\partial v_{21}} \Big|_{\theta^{(0)}, \#1} = -0.050000 - 0.5 \cdot (-0.003155) = -0.0484225 \approx -0.048423$$

$$v_{22}^{(1)} = v_{22}^{(0)} - \eta \frac{\partial L}{\partial v_{22}} \Big|_{\theta^{(0)}, \#1} = 0.100000 - 0.5 \cdot (-0.003131) = 0.1015655 \approx 0.101566$$

$$v_{23}^{(1)} = v_{23}^{(0)} - \eta \frac{\partial L}{\partial v_{23}} \Big|_{\theta^{(0)}, \#1} = 0.100000 - 0.5 \cdot (-0.003213) = 0.1016065 \approx 0.101607$$

$$c_2^{(1)} = c_2^{(0)} - \eta \frac{\partial L}{\partial c_2} \Big|_{\theta^{(0)}, \#1} = 0 - 0.5 \cdot (-0.006237) = 0.0031185 \approx 0.003118$$

Output.

$$u_1^{(1)} = u_1^{(0)} - \eta \frac{\partial L}{\partial u_1} \Big|_{\theta^{(0)}, \#1} = 0.100000 - 0.5 \cdot 0.126554 = 0.036723$$

$$u_2^{(1)} = u_2^{(0)} - \eta \frac{\partial L}{\partial u_2} \Big|_{\theta^{(0)}, \#1} = -0.100000 - 0.5 \cdot 0.129693 = -0.1648465 \approx -0.164847$$

$$d^{(1)} = d^{(0)} - \eta \frac{\partial L}{\partial d} \Big|_{\theta^{(0)}, \#1} = 0 - 0.5 \cdot 0.249843 = -0.1249215 \approx -0.124921$$

Iterazione 2: SGD su esempio #2

Input: $x_1 = 0.800000$, $x_2 = 0.533300$, $x_3 = 0.450000$, $y = 1$

Parametri all'inizio dell'iterazione

Strato 1 (w, b):

$$\begin{aligned}w_{11} &= 0.099901, w_{12} = -0.200051, w_{13} = 0.099971, b_1 = -0.000117 \\w_{21} &= -0.099867, w_{22} = 0.100068, w_{23} = 0.200039, b_2 = 0.000156 \\w_{31} &= 0.050033, w_{32} = 0.100017, w_{33} = -0.099990, b_3 = 3.889468e - 05\end{aligned}$$

Strato 2 (v, c):

$$\begin{aligned}v_{11} &= 0.098421, v_{12} = -0.101568, v_{13} = 0.048391, c_1 = -0.003123 \\v_{21} &= -0.048423, v_{22} = 0.101566, v_{23} = 0.101607, c_2 = 0.003118\end{aligned}$$

Output (u, d):

$$u_1 = 0.036723, u_2 = -0.164847, d = -0.124921$$

Forward (tutti i valori intermedi)

Strato 1:

$$\begin{aligned}z_1 &= w_{11}x_1 + w_{12}x_2 + w_{13}x_3 + b_1 = (0.099901)(0.800000) + (-0.200051)(0.533300) + (0.099971)(0.450000) + (-0.000117) \\a_1 &= \sigma(z_1) = \sigma(0.018103) = 0.504526 \\z_2 &= w_{21}x_1 + w_{22}x_2 + w_{23}x_3 + b_2 = (-0.099867)(0.800000) + (0.100068)(0.533300) + (0.200039)(0.450000) + (0.000156) \\a_2 &= \sigma(z_2) = \sigma(0.063646) = 0.515906 \\z_3 &= w_{31}x_1 + w_{32}x_2 + w_{33}x_3 + b_3 = (0.050033)(0.800000) + (0.100017)(0.533300) + (-0.099990)(0.450000) + (3.889468e - 05) \\a_3 &= \sigma(z_3) = \sigma(0.048409) = 0.512100\end{aligned}$$

Strato 2:

$$\begin{aligned}s_1 &= v_{11}a_1 + v_{12}a_2 + v_{13}a_3 + c_1 = (0.098421)(0.504526) + (-0.101568)(0.515906) + (0.048391)(0.512100) + (-0.003123) \\g_1 &= \sigma(s_1) = \sigma(0.018915) = 0.504729 \\s_2 &= v_{21}a_1 + v_{22}a_2 + v_{23}a_3 + c_2 = (-0.048423)(0.504526) + (0.101566)(0.515906) + (0.101607)(0.512100) + (0.003118) \\g_2 &= \sigma(s_2) = \sigma(0.083119) = 0.520768\end{aligned}$$

Output:

$$\begin{aligned}t &= u_1g_1 + u_2g_2 + d = (0.036723)(0.504729) + (-0.164847)(0.520768) + (-0.124921) = -0.192233 \\y &= \sigma(t) = \sigma(-0.192233) = 0.452089\end{aligned}$$

Loss (MSE su 2 esempio)

$$L = (\hat{y} - y)^2 = (0.452089 - 1)^2 = 0.300206$$

Backprop: deltas (error signals)

$$\frac{dL}{d\hat{y}} = 2(\hat{y} - y) = 2(0.452089 - 1) = -1.095822$$

$$\frac{d\hat{y}}{dt} = \hat{y}(1 - \hat{y}) = (0.452089)(1 - 0.452089) = 0.247705$$

$$\delta_{out} = \frac{dL}{dt} = \frac{dL}{d\hat{y}} \frac{d\hat{y}}{dt} = -1.095822 \cdot 0.247705 = -0.271440$$

$$\delta_{g1} = \frac{dL}{ds_1} = \delta_{out} u_1 g_1 (1 - g_1) = -0.271440 \cdot 0.036723 \cdot (0.504729)(1 - 0.504729) = -0.002492$$

$$\delta_{g2} = \frac{dL}{ds_2} = \delta_{out} u_2 g_2 (1 - g_2) = -0.271440 \cdot -0.164847 \cdot (0.520768)(1 - 0.520768) = 0.011167$$

$$\delta_{a1} = \frac{dL}{dz_1} = (\delta_{g1} v_{11} + \delta_{g2} v_{21}) a_1 (1 - a_1) = (-0.002492 \cdot 0.098421 + 0.011167 \cdot -0.048423) \cdot (0.504526)(1 - 0.504526)$$

$$\delta_{a2} = \frac{dL}{dz_2} = (\delta_{g1} v_{12} + \delta_{g2} v_{22}) a_2 (1 - a_2) = (-0.002492 \cdot -0.101568 + 0.011167 \cdot 0.101566) \cdot (0.515906)(1 - 0.515906)$$

$$\delta_{a3} = \frac{dL}{dz_3} = (\delta_{g1} v_{13} + \delta_{g2} v_{23}) a_3 (1 - a_3) = (-0.002492 \cdot 0.048391 + 0.011167 \cdot 0.101607) \cdot (0.512100)(1 - 0.512100)$$

Tutti i gradienti (23 valori)

$$\frac{dL}{du_1} = \delta_{out}g_1 = -0.271440 \cdot 0.504729 = -0.137004$$

$$\frac{dL}{du_2} = \delta_{out}g_2 = -0.271440 \cdot 0.520768 = -0.141357$$

$$\frac{dL}{dd} = \delta_{out} = -0.271440$$

$$\frac{dL}{dv_{11}} = \delta_{g1}a_1 = -0.002492 \cdot 0.504526 = -0.001257$$

$$\frac{dL}{dv_{12}} = \delta_{g1}a_2 = -0.002492 \cdot 0.515906 = -0.001286$$

$$\frac{dL}{dv_{13}} = \delta_{g1}a_3 = -0.002492 \cdot 0.512100 = -0.001276$$

$$\frac{dL}{dc_1} = \delta_{g1} = -0.002492$$

$$\frac{dL}{dv_{21}} = \delta_{g2}a_1 = 0.011167 \cdot 0.504526 = 0.005634$$

$$\frac{dL}{dv_{22}} = \delta_{g2}a_2 = 0.011167 \cdot 0.515906 = 0.005761$$

$$\frac{dL}{dv_{23}} = \delta_{g2}a_3 = 0.011167 \cdot 0.512100 = 0.005719$$

$$\frac{dL}{dc_2} = \delta_{g2} = 0.011167$$

$$\frac{dL}{dw_{11}} = \delta_{a1}x_1 = -0.000196 \cdot 0.800000 = -0.000157$$

$$\frac{dL}{dw_{12}} = \delta_{a1}x_2 = -0.000196 \cdot 0.533300 = -0.000105$$

$$\frac{dL}{dw_{13}} = \delta_{a1}x_3 = -0.000196 \cdot 0.450000 = -8.841657e - 05$$

$$\frac{dL}{db_1} = \delta_{a1} = -0.000196$$

$$\frac{dL}{dw_{21}} = \delta_{a2}x_1 = 0.000346 \cdot 0.800000 = 0.000277$$

$$\frac{dL}{dw_{22}} = \delta_{a2}x_2 = 0.000346 \cdot 0.533300 = 0.000185$$

$$\frac{dL}{dw_{23}} = \delta_{a2}x_3 = 0.000346 \cdot 0.450000 = 0.000156$$

$$\frac{dL}{db_2} = \delta_{a2} = 0.000346$$

$$\frac{dL}{dw_{31}} = \delta_{a3}x_1 = 0.000253 \cdot 0.800000 = 0.000203$$

$$\frac{dL}{dw_{32}} = \delta_{a3}x_2 = 0.000253 \cdot 0.533300 = 0.000135$$

$$\frac{dL}{dw_{33}} = \delta_{a3}x_3 = 0.000253 \cdot 0.450000 = 0.000114$$

$$\frac{dL}{db_3} = \delta_{a3} = 0.000253$$

Update (SGD)

$$\theta \leftarrow \theta - \eta \frac{dL}{d\theta} \quad (\eta = 0.5)$$

Parametri dopo l'update (fine iterazione):

Strato 1 (w, b):

$w_{11} = 0.099979$, $w_{12} = -0.199998$, $w_{13} = 0.100015$, $b_1 = -1.878695e - 05$
 $w_{21} = -0.100006$, $w_{22} = 0.099975$, $w_{23} = 0.199961$, $b_2 = -1.721421e - 05$
 $w_{31} = 0.049932$, $w_{32} = 0.099949$, $w_{33} = -0.100047$, $b_3 = -8.779105e - 05$

Strato 2 (v, c):

$v_{11} = 0.099049$, $v_{12} = -0.100925$, $v_{13} = 0.049029$, $c_1 = -0.001877$
 $v_{21} = -0.051240$, $v_{22} = 0.098685$, $v_{23} = 0.098747$, $c_2 = -0.002465$

Output (u, d):

$u_1 = 0.105225$, $u_2 = -0.094168$, $d = 0.010799$

Calcolo esplicito degli aggiornamenti (Iterazione 2)

Regola teorica di update (SGD su 1 esempio).

$$\theta^{(2)} = \theta^{(1)} - \eta \left. \frac{\partial L}{\partial \theta} \right|_{\theta^{(1)}, \text{esempio \#2}}$$

dove $\eta = 0.5$ e il gradiente è quello calcolato nella backprop dell'iterazione 2.

Strato 1.

$$w_{11}^{(2)} = w_{11}^{(1)} - \eta \left. \frac{\partial L}{\partial w_{11}} \right|_{\theta^{(1)}, \#2} = 0.099901 - 0.5 \cdot (-0.000157) = 0.0999795 \approx 0.099979$$

$$w_{12}^{(2)} = w_{12}^{(1)} - \eta \left. \frac{\partial L}{\partial w_{12}} \right|_{\theta^{(1)}, \#2} = -0.200051 - 0.5 \cdot (-0.000105) = -0.1999985 \approx -0.199998$$

$$w_{13}^{(2)} = w_{13}^{(1)} - \eta \left. \frac{\partial L}{\partial w_{13}} \right|_{\theta^{(1)}, \#2} = 0.099971 - 0.5 \cdot (-8.841657 \times 10^{-5}) = 0.1000152 \approx 0.100015$$

$$b_1^{(2)} = b_1^{(1)} - \eta \left. \frac{\partial L}{\partial b_1} \right|_{\theta^{(1)}, \#2} = -0.000117 - 0.5 \cdot (-0.000196) = -1.9 \times 10^{-5} \approx -1.878695 \times 10^{-5}$$

(...e così via identico per tutti gli altri parametri, usando sempre $\theta^{(1)}$ come “valore prima” e i gradienti dell'iterazione 2.)

Iterazione 3: SGD su esempio #3

Input: $x_1 = 0.900000$, $x_2 = 0.600000$, $x_3 = 0.350000$, $y = 1$

Parametri all'inizio dell'iterazione

Strato 1 (w, b):

$w_{11} = 0.099979$, $w_{12} = -0.199998$, $w_{13} = 0.100015$, $b_1 = -1.878695e - 05$
 $w_{21} = -0.100006$, $w_{22} = 0.099975$, $w_{23} = 0.199961$, $b_2 = -1.721421e - 05$
 $w_{31} = 0.049932$, $w_{32} = 0.099949$, $w_{33} = -0.100047$, $b_3 = -8.779105e - 05$

Strato 2 (v, c):

$v_{11} = 0.099049$, $v_{12} = -0.100925$, $v_{13} = 0.049029$, $c_1 = -0.001877$

$$v_{21} = -0.051240, v_{22} = 0.098685, v_{23} = 0.098747, c_2 = -0.002465$$

Output (u, d):

$$u_1 = 0.105225, u_2 = -0.094168, d = 0.010799$$

Forward (tutti i valori intermedi)

Strato 1:

$$z_1 = w_{11}x_1 + w_{12}x_2 + w_{13}x_3 + b_1 = (0.099979)(0.900000) + (-0.199998)(0.600000) + (0.100015)(0.350000) + (-0.000000) = 0.004969$$

$$a_1 = \sigma(z_1) = \sigma(0.004969) = 0.501242$$

$$z_2 = w_{21}x_1 + w_{22}x_2 + w_{23}x_3 + b_2 = (-0.100006)(0.900000) + (0.099975)(0.600000) + (0.199961)(0.350000) + (-0.000000) = 0.039949$$

$$a_2 = \sigma(z_2) = \sigma(0.039949) = 0.509986$$

$$z_3 = w_{31}x_1 + w_{32}x_2 + w_{33}x_3 + b_3 = (0.049932)(0.900000) + (0.099949)(0.600000) + (-0.100047)(0.350000) + (-0.000000) = 0.069804$$

$$a_3 = \sigma(z_3) = \sigma(0.069804) = 0.517444$$

Strato 2:

$$s_1 = v_{11}a_1 + v_{12}a_2 + v_{13}a_3 + c_1 = (0.099049)(0.501242) + (-0.100925)(0.509986) + (0.049029)(0.517444) + (-0.000000) = 0.021671$$

$$g_1 = \sigma(s_1) = \sigma(0.021671) = 0.505417$$

$$s_2 = v_{21}a_1 + v_{22}a_2 + v_{23}a_3 + c_2 = (-0.051240)(0.501242) + (0.098685)(0.509986) + (0.098747)(0.517444) + (-0.002465) = 0.073276$$

$$g_2 = \sigma(s_2) = \sigma(0.073276) = 0.518311$$

Output:

$$t = u_1g_1 + u_2g_2 + d = (0.105225)(0.505417) + (-0.094168)(0.518311) + (0.010799) = 0.015173$$

$$\hat{y} = \sigma(t) = \sigma(0.015173) = 0.503793$$

Loss (MSE su 3 esempio)

$$L = (\hat{y} - y)^2 = (0.503793 - 1)^2 = 0.246221$$

Backprop: deltas (error signals)

$$\frac{dL}{d\hat{y}} = 2(\hat{y} - y) = 2(0.503793 - 1) = -0.992414$$

$$\frac{d\hat{y}}{dt} = \hat{y}(1 - \hat{y}) = (0.503793)(1 - 0.503793) = 0.249986$$

$$\delta_{out} = \frac{dL}{dt} = \frac{dL}{d\hat{y}} \frac{d\hat{y}}{dt} = -0.992414 \cdot 0.249986 = -0.248089$$

$$\delta_{g1} = \frac{dL}{ds_1} = \delta_{out}u_1g_1(1 - g_1) = -0.248089 \cdot 0.105225 \cdot (0.505417)(1 - 0.505417) = -0.006526$$

$$\delta_{g2} = \frac{dL}{ds_2} = \delta_{out}u_2g_2(1 - g_2) = -0.248089 \cdot -0.094168 \cdot (0.518311)(1 - 0.518311) = 0.005833$$

$$\delta_{a1} = \frac{dL}{dz_1} = (\delta_{g1}v_{11} + \delta_{g2}v_{21})a_1(1 - a_1) = (-0.006526 \cdot 0.099049 + 0.005833 \cdot -0.051240) \cdot (0.501242)(1 - 0.501242) = -0.000000$$

$$\delta_{a2} = \frac{dL}{dz_2} = (\delta_{g1}v_{12} + \delta_{g2}v_{22})a_2(1 - a_2) = (-0.006526 \cdot -0.100925 + 0.005833 \cdot 0.098685) \cdot (0.509986)(1 - 0.509986) = 0.000000$$

$$\delta_{a3} = \frac{dL}{dz_3} = (\delta_{g1}v_{13} + \delta_{g2}v_{23})a_3(1 - a_3) = (-0.006526 \cdot 0.049029 + 0.005833 \cdot 0.098747) \cdot (0.517444)(1 - 0.517444) = 0.000000$$

Tutti i gradienti (23 valori)

$$\frac{dL}{du_1} = \delta_{out}g_1 = -0.248089 \cdot 0.505417 = -0.125389$$

$$\frac{dL}{du_2} = \delta_{out}g_2 = -0.248089 \cdot 0.518311 = -0.128587$$

$$\frac{dL}{dd} = \delta_{out} = -0.248089$$

$$\frac{dL}{dv_{11}} = \delta_{g1}a_1 = -0.006526 \cdot 0.501242 = -0.003271$$

$$\frac{dL}{dv_{12}} = \delta_{g1}a_2 = -0.006526 \cdot 0.509986 = -0.003328$$

$$\frac{dL}{dv_{13}} = \delta_{g1}a_3 = -0.006526 \cdot 0.517444 = -0.003377$$

$$\frac{dL}{dc_1} = \delta_{g1} = -0.006526$$

$$\frac{dL}{dv_{21}} = \delta_{g2}a_1 = 0.005833 \cdot 0.501242 = 0.002924$$

$$\frac{dL}{dv_{22}} = \delta_{g2}a_2 = 0.005833 \cdot 0.509986 = 0.002975$$

$$\frac{dL}{dv_{23}} = \delta_{g2}a_3 = 0.005833 \cdot 0.517444 = 0.003018$$

$$\frac{dL}{dc_2} = \delta_{g2} = 0.005833$$

$$\frac{dL}{dw_{11}} = \delta_{a1}x_1 = -0.000236 \cdot 0.900000 = -0.000213$$

$$\frac{dL}{dw_{12}} = \delta_{a1}x_2 = -0.000236 \cdot 0.600000 = -0.000142$$

$$\frac{dL}{dw_{13}} = \delta_{a1}x_3 = -0.000236 \cdot 0.350000 = -8.270554e-05$$

$$\frac{dL}{db_1} = \delta_{a1} = -0.000236$$

$$\frac{dL}{dw_{21}} = \delta_{a2}x_1 = 0.000308 \cdot 0.900000 = 0.000278$$

$$\frac{dL}{dw_{22}} = \delta_{a2}x_2 = 0.000308 \cdot 0.600000 = 0.000185$$

$$\frac{dL}{dw_{23}} = \delta_{a2}x_3 = 0.000308 \cdot 0.350000 = 0.000108$$

$$\frac{dL}{db_2} = \delta_{a2} = 0.000308$$

$$\frac{dL}{dw_{31}} = \delta_{a3}x_1 = 6.392714e-05 \cdot 0.900000 = 5.753443e-05$$

$$\frac{dL}{dw_{32}} = \delta_{a3}x_2 = 6.392714e-05 \cdot 0.600000 = 3.835629e-05$$

$$\frac{dL}{dw_{33}} = \delta_{a3}x_3 = 6.392714e-05 \cdot 0.350000 = 2.237450e-05$$

$$\frac{dL}{db_3} = \delta_{a3} = 6.392714e-05$$

Update (SGD)

$$\theta \leftarrow \theta - \eta \frac{dL}{d\theta} \quad (\eta = 0.5)$$

Parametri dopo l'update (fine iterazione):

Strato 1 (w, b):

$w_{11} = 0.100085$, $w_{12} = -0.199927$, $w_{13} = 0.100056$, $b_1 = 9.936382e - 05$
 $w_{21} = -0.100145$, $w_{22} = 0.099883$, $w_{23} = 0.199907$, $b_2 = -0.000171$
 $w_{31} = 0.049903$, $w_{32} = 0.099930$, $w_{33} = -0.100058$, $b_3 = -0.000120$

Strato 2 (v, c):

$v_{11} = 0.100685$, $v_{12} = -0.099261$, $v_{13} = 0.050718$, $c_1 = 0.001386$
 $v_{21} = -0.052701$, $v_{22} = 0.097198$, $v_{23} = 0.097238$, $c_2 = -0.005381$

Output (u, d):

$u_1 = 0.167919$, $u_2 = -0.029874$, $d = 0.134843$

Calcolo esplicito degli aggiornamenti (Iterazione 3)

Regola teorica di update (SGD su 1 esempio).

$$\theta^{(3)} = \theta^{(2)} - \eta \left. \frac{\partial L}{\partial \theta} \right|_{\theta^{(2)}, \text{esempio \#3}}$$

dove $\eta = 0.5$ e il gradiente è quello calcolato nella backprop dell'iterazione 3.

Strato 1.

$$w_{11}^{(3)} = w_{11}^{(2)} - \eta \left. \frac{\partial L}{\partial w_{11}} \right|_{\theta^{(2)}, \#3} = 0.099979 - 0.5 \cdot (-0.000213) = 0.1000855 \approx 0.100085$$

(... e così via per tutti gli altri parametri, usando $\theta^{(2)}$ come “valore prima” e i gradienti dell'iterazione 3.)

7. Parametri finali dopo 3 iterazioni

Strato 1 (w, b):

$w_{11} = 0.100085$, $w_{12} = -0.199927$, $w_{13} = 0.100056$, $b_1 = 9.936382e - 05$
 $w_{21} = -0.100145$, $w_{22} = 0.099883$, $w_{23} = 0.199907$, $b_2 = -0.000171$
 $w_{31} = 0.049903$, $w_{32} = 0.099930$, $w_{33} = -0.100058$, $b_3 = -0.000120$

Strato 2 (v, c):

$v_{11} = 0.100685$, $v_{12} = -0.099261$, $v_{13} = 0.050718$, $c_1 = 0.001386$
 $v_{21} = -0.052701$, $v_{22} = 0.097198$, $v_{23} = 0.097238$, $c_2 = -0.005381$

Output (u, d):

$u_1 = 0.167919$, $u_2 = -0.029874$, $d = 0.134843$

Perché la loss può aumentare in SGD

Contesto

Consideriamo la rete neurale $3 \rightarrow 3 \rightarrow 2 \rightarrow 1$ definita nelle sezioni precedenti, addestrata con **Stochastic Gradient Descent** (SGD) su esempi singoli.

Loss sui primi 3 esempi

	Esempio #1 ($y = 0$)	Esempio #2 ($y = 1$)	Esempio #3 ($y = 1$)
Prima di update	0.249686	0.250332	0.250329
Dopo update #1	0.204396	0.300210	0.300210
Dopo update #2	0.253822	0.246224	0.246222

Interpretazione

- Dopo l'update sull'esempio #1 la loss su #1 diminuisce, ma quella su #2 e #3 può aumentare. Questo accade perché l'update è ottimizzato *solo* per l'esempio corrente.
- In SGD non è garantita una diminuzione monotona della loss per singolo esempio.
- È quindi corretto monitorare la **loss media** su più esempi o su un mini-batch.

Come leggere la tabella delle loss (training vs valutazione)

È importante distinguere tra:

- **loss di training (SGD)**: è la loss usata per calcolare i gradienti e aggiornare i pesi nell'iterazione corrente. Alla iterazione k (SGD “vero”) si usa *solo* l'esempio corrente k :

$$L^{(k)}(\theta_k) = (\hat{y}^{(k)}(\theta_k) - y^{(k)})^2, \quad \theta_{k+1} = \theta_k - \eta \nabla_{\theta} L^{(k)}(\theta_k).$$

Questa $L^{(k)}$ è l'unica loss che influenza l'update dei pesi in quell'iterazione.

- **loss di valutazione (monitoraggio)**: dopo aver ottenuto un certo set di pesi θ (ad esempio “prima di update”, “dopo update #1”, “dopo update #2”), si può calcolare *a posteriori* la loss su più esempi per capire come l'update ha influenzato la rete. In questo caso i pesi θ sono *fissi* e non si fa backprop su questi esempi: si fa solo forward.

Cosa rappresenta ogni cella della tabella. Ogni cella è una loss *per-esempio* calcolata con un set di pesi fissato:

$$L_i(\theta) = (\hat{y}_i(\theta) - y_i)^2,$$

dove $i \in \{1, 2, 3\}$ indica l'esempio (colonna della tabella) e θ indica lo stato dei pesi (riga della tabella).

Significato delle righe.

- **Prima di update**: loss calcolata sui tre esempi usando i pesi iniziali θ_0 .
- **Dopo update #1**: loss calcolata sui tre esempi usando i pesi θ_1 ottenuti *dopo* aver fatto SGD sull'esempio #1.
- **Dopo update #2**: loss calcolata sui tre esempi usando i pesi θ_2 ottenuti *dopo* aver fatto SGD sull'esempio #2.

Perché la loss può aumentare tra iterazioni. In SGD non è garantito che la loss su *tutti* gli esempi diminuisca ad ogni update: l'update è ottimizzato per ridurre $L^{(k)}$ dell'esempio corrente, e può temporaneamente aumentare L_i su altri esempi. Per questo, in pratica, si monitora spesso la **loss media** su un insieme di esempi (o su un mini-batch), non la loss di un singolo esempio.